

基于 CRITIC-XGB 算法的岩爆倾向等级预测模型

谢学斌, 李德玄, 孔令燕, 叶永飞, 高山

(中南大学 资源与安全工程学院, 湖南 长沙 410083)

摘要: 为了更精确地对岩爆倾向等级进行预测, 根据岩爆的成因和特点选取了围岩切向应力, 围岩切向应力和单轴抗压强度的比值, 岩石脆性指数和岩石的弹性变形能量指数作为岩爆倾向等级预测指标, 然后运用改进的 CRITIC 算法对指标样本进行加权处理, 在此基础上引入新的机器学习算法 XGBoost 对样本进行计算训练, 最终建立岩爆倾向等级预测的 CRITIC-XGB 模型。运用该模型对收集的岩爆实例进行了岩爆倾向等级预测, 并将预测结果与 XGBoost、随机森林(RF)和支持向量机(SVM)算法的预测结果进行分析研究。研究结果表明: CRITIC-XGB 预测模型较单一的 XGBoost 模型的收敛性能有较为明显的提高; CRITIC-XGB 预测模型较单一的 XGBoost 算法、RF 和 SVM 算法, 有更高的预测准确性, 为岩爆倾向等级预测提供了一种新的可靠方法。

关键词: 岩石力学; 岩爆等级; 智能算法; 预测模型; CRITIC 法; XGBoost

中图分类号: TU 45

文献标识码: A

文章编号: 1000 - 6915(2020)10 - 1975 - 08

Rockburst propensity prediction model based on CRITIC-XGB algorithm

XIE Xuebin, LI Dexuan, KONG Lingyan, YE Yongfei, GAO Shan

(School of Resources and Safety Engineering, Central South University, Changsha, Hunan 410083, China)

Abstract: In order to predict the rockburst tendency level more accurately, shear stress of surrounding rock, ratio of shear stress of surrounding rock and compressive strength, brittleness index and elastic deformation energy index are selected as the prediction indexes of rockburst tendency level according to the cause and characteristics of rockburst, and the improved CRITIC algorithm is used to weight the indicator samples. A new machine learning algorithm named as XGBoost is introduced to perform computational training on the samples, and a CRITIC-XGB model of rockburst tendency level prediction is established. The model is used to predict the rockburst tendency level of the collected rockburst instances, and the prediction results are compared with those by XGBoost, random forest(RF) and support vector machine(SVM) algorithms. The research results show that the convergence performance of the CRITIC-XGB prediction model is significantly improved compared to the single XGBoost model and that the CRITIC-XGB prediction model has higher prediction accuracy than the single XGBoost, RF and SVM algorithms. The developed model provides a new and reliable method for the prediction of rockburst tendency grades.

Key words: rock mechanics; rockburst level; intelligent algorithm; prediction model; CRITIC method; XGBoost

1 引言

岩爆是发生在地下岩石工程中的一种动力地质

灾害, 它是处于高应力或极限平衡状态的岩体或地质结构体在卸压时, 其岩体内部储存的应变能在极短时间内剧烈释放, 造成开挖空间周围部分岩石的动力失稳现象。其通常表现为空区围岩片状剥落、

收稿日期: 2019 - 11 - 04; **修回日期:** 2019 - 12 - 11

基金项目: 中南大学中央高校基本科研业务费专项资金资助(2018zzts715); 广西重点研发计划资助(桂科AB18294004)

Supported by the Central University of Central South University for Basic Research Business Expenses(Grant No. 2018zzts715) and Guangxi Key R&D Program(Grant No. GUI-AB18294004)

作者简介: 谢学斌(1968 -), 男, 1988 年毕业于中南大学采矿工程专业, 现任教授, 主要从事岩土工程、采矿工程、安全工程方面的教学与研究工作。

E-mail: 912035278@qq.com

DOI: 10.13722/j.cnki.jrme.2019.1049

严重片帮, 严重者伴有巨大声响及岩块弹射、洞室突然破坏, 给人员、设备和建筑的安全带来巨大威胁^[1]。近年来, 随着矿山开采的深部化, 隧道工程的大型化, 岩爆已经成为地下空间工程中重要的灾害问题之一, 寻找岩爆倾向等级预测的更有效的方法对岩爆的灾害防治有着重要意义。

从岩爆现象被发现开始, 岩爆的倾向性预测研究就吸引了大批国内外专家学者的关注和研究。目前, 有学者从单一因素出发对岩爆进行预测研究, 并提出了一系列判据, 比如: Russenes 应力判据^[2]、王元汉判据^[3]、陆家佑判据^[4], 但是岩爆的发生受多种因素的共同作用, 且因素间相互关联影响, 所以岩爆具有极高的复杂性、和不确定性, 使得从机制出发对岩爆进行预测的可靠度不高。有部分学者利用模糊数学理论和智能算法对岩爆倾向等级进行预测, 并取得了较好的预测效果。目前应用较广泛的方法包括: 模糊综合评判法^[5]、贝叶斯判别法^[6]、云模型法^[6]、灰色理论法^[7]、神经网络法^[8]、支持向量机法^[9]、随机森林法^[10]等, 虽然这些方法的应用提高了岩爆倾向等级预测的精度, 但都存在某些方面的缺陷和不足: 模糊综合评判法受到评判标准的制约, 人为的影响因素较大, 对岩爆的分类预测不够客观; 贝叶斯判别法对于指标间相关性较大的数据集分类效果较差; 灰色理论受原始数据影响较大; 神经网络法和支持向量机法需要大量的数据进行训练, 且模型收敛速度慢, 精度亦不高; 随机森林法对于小样本和低维数据的预测效果较差。由于岩爆的发生具有高度的复杂性和不确定性, 单一分类方法和算法难以对其进行准确预测, 需要多种方法结合, 运用集成算法以提高预测精度。

本文模型综合了模糊数学和智能算法的在岩爆预测方面的优势, 将改进的 CRITIC 法与机器学习中的最新成果 XGBoost 结合起来用于对岩爆倾向进行预测分级。其中改进的 CRITIC 法用于对样本数据进行预处理, 消除指标间由于量纲不同而数值差异较大的问题, 使样本数据更清晰地反应出指标的重要程度; XGBoost 是一种集成分类算法, 不仅拥有较高的预测精度, 且泛化能力强。将两者结合运用于岩爆倾向等级预测, 建立了岩爆倾向等级预测的 CRITIC-XGB 模型, 并将其应用于岩爆实例的预测, 预测结果与实际情况基本相符, 证明了 CRITIC-XGB 模型在岩爆倾向预测中的可靠性和实用性。

2 CRITIC-XGB 算法原理

2.1 改进的 CRITIC 算法

本文选取改进的 CRITIC 法, 其由 D. Diakoulaki 等^[11]在 1995 年提出, 其核心思想是基于指标的变异性和指标间的冲突性来赋予各指标权重。指标的变异性反映了指标所含有的信息量大小, 通过指标的标准差来衡量, 标准差越大, 样本指标的取值差异越大, 所含信息量越多, 相应的指标的权重应越高; 指标间的冲突性反映了指标间的相关性的大小, 指标间的相关性通过相关系数来衡量, 指标间相关系数越大, 其冲突性越小, 说明 2 个指标所提供的重复信息多, 相应指标权重应越小。

改进的 CRITIC 法不仅考虑了指标自身所含信息量多少, 而且考虑了指标间的相关性, 能根据数据样本计算出指标的重要程度, 且能消除因量纲不同引起的数值大小悬殊的差异, 其主要步骤如下^[12]:

(1) m 个样本和 n 个指标的第 i 个对象的第 j 个指标取值 x_{ij} 构成原始样本数据矩阵 $\mathbf{X} = (x_{ij})_{m \times n}$ 。

(2) 为消除量纲引起的指标的数量级上的差异, 先采用 Z-score 方法将 $\mathbf{X}$ 中各指标值标准化, 得到标准化矩阵 $\mathbf{X}^*$:

$$x_{ij}^* = \frac{x_{ij} - \bar{x}_j}{s_j} \quad (i=1, 2, \dots, m; \quad j=1, 2, \dots, n) \quad (1a)$$

式中: $\bar{x}_j$ 和 s_j 分别为第 j 个指标的均值和标准差, 计算式为

$$\left. \begin{aligned} \bar{x}_j &= \frac{1}{m} \sum_{i=1}^m x_{ij} \\ s_j &= \sqrt{\frac{1}{m-1} \sum_{i=1}^m (x_{ij} - \bar{x}_j)^2} \end{aligned} \right\} \quad (1b)$$

(3) 计算各指标变异系数:

$$v_j = \frac{s_j}{\bar{x}_j} \quad (2)$$

式中: v_j 为第 j 个指标的变异系数。

(4) 计算标准化矩阵 $\mathbf{X}^*$ 各指标的相关性系数, 得到相关系数矩阵:

$$\mathbf{R} = (r_{kl})_{n \times n} \quad (k=1, 2, \dots, n; \quad l=1, 2, \dots, n) \quad (3)$$

式中: r_{kl} 为第 k, l 个指标间的相关系数。

(5) 计算反映各指标独立程度的系数:

$$\eta_j = \sum_{k=1}^n (1 - r_{kj}) \quad (j=1, 2, \dots, n) \quad (4)$$

(6) 计算反映各指标的综合信息量的系数:

$$C_j = v_j \eta_j \quad (j=1, 2, 3, \dots, n) \quad (5)$$

(7) 计算各指标权重:

$$\omega_j = \frac{C_j}{\sum_{j=1}^n C_j} \quad (j=1, 2, 3, \dots, n) \quad (6)$$

(8) 得到最终样本矩阵 $\mathbf{X}^t$:

$$x_{ij}^t = \omega_j x_{ij}^* \quad (i=1, 2, \dots, m; j=1, 2, \dots, n) \quad (7)$$

2.2 XGBoost 算法

XGBoost 属于集成分类算法, 全称为 extreme gradient boosting^[13], 是一种基于决策树(CART)的分布式高效梯度提升算法, 其基本思想是将若干低精度的弱分类器组合成一个高精度的分类器。XGBoost 在损失函数中加入正则项, 并对损失函数做二阶泰勒展开, 提高了计算精度, 有效避免了算法过拟合; 而且采用了特征列抽样, 不仅进一步提高了拟合效果, 也降低了算法计算量; 同时 XGBoost 算法可以实现分布式计算。与同类提升树算法相比, XGBoost 在拟合精度上和计算速度上有着更大优势。

XGBoost 算法基本原理如下^[14], 对于给定数据集 $D = \{(X_i, y_i)\}$, 基于分类决策树(CART)作为基分类器定义模型函数:

$$\hat{y}_i = \phi(X_i) = \sum_{k=1}^K f_k(X_i) \quad (f_k \in F) \quad (8a)$$

其中,

$$F = \{f(X) = \omega_{q(X)}\} \quad (q: \mathbb{R}^m \rightarrow T, \omega \in \mathbb{R}^T) \quad (8b)$$

式中: K 为决策树数量; F 为决策树空间; $q(X)$ 为将样本 X 映射到树的叶子节点, 其对应叶子节点的分数为 $\omega_{q(X)}$; $\mathbb{R}^m$ 为 m 维实向量; T 为对应的树的节点数; $\mathbb{R}^T$ 为 T 维实向量。

定义用于模型优化的目标函数, 其由损失目标函数和正则项构成:

$$\left. \begin{aligned} ojb &= \sum_{i=1}^n l(y_i, \hat{y}_i) + \sum_{k=1}^K \Omega(f_k) \\ \Omega(f_k) &= \alpha T + \frac{1}{2} \lambda \sum_{j=1}^T \omega_j^2 \end{aligned} \right\} \quad (9)$$

式中: ojb 为损失目标函数; $l(y_i, \hat{y}_i)$ 为样本 x_i 的训练误差; $\hat{y}_i, y_i$ 分别为样本 x_i 预测等级和实际等级; $\Omega(f_k)$ 为第 k 棵分类回归树的正则项; T 为 CART 叶节点个数; ω_j 为第 j 个叶节点的权重; α, λ 均为惩罚系数。

XGBoost 算法在训练过程中按比例随机选取训练集和测试集, 当迭代至第 t 轮时, 模型目标函数表示如下:

$$ojb^{(t)} = \sum_{i=1}^n l(y_i, \hat{y}_i^{t-1} + f_t(x_i)) + \sum_{k=1}^K \Omega(f_k) + C \quad (10)$$

式中: $f_t(x_i)$ 为加入的第 t 棵分类回归树, C 为前 $t-1$ 棵树的复杂度。

对式(10)以二阶泰勒公式做近似展开, 得出目标函数的近似表达式为

$$ojb^{(t)} \simeq \sum_{i=1}^n l \left[y_i, \hat{y}_i^{t-1} + g_i f_t(x_i) + \frac{1}{2} h_i f_t^2(x_i) \right] + \sum_{k=1}^K \Omega(f_k) + C \quad (11)$$

式中: g_i 为 $l(y_i, \hat{y}_i^{t-1})$ 对 $\hat{y}_i^{t-1}$ 的一阶导数, h_i 为 $l(y_i, \hat{y}_i^{t-1})$ 对 $\hat{y}_i^{t-1}$ 的二阶导数。化简后可得到最终的目标函数:

$$ojb^{(t)} \simeq \sum_{i=1}^T \left[\left(\sum_{i \in I_j} g_i \right) \omega_j + \frac{1}{2} \left(\sum_{i \in I_j} h_i + \lambda \right) \omega_j^2 \right] + \alpha T \quad (12)$$

对目标函数 $ojb(t)$ 求关于 ω_j 的偏导, 并令偏导数等于 0, 得到令目标函数取最小值的最优权重:

$$\omega_j^* = \frac{\sum_{i \in I_j} g_i}{\sum_{i \in I_j} h_i + \lambda} \quad (13)$$

将式(13)代入式(12), 得到目标函数的最小值:

$$ojb^{(t)} = -\frac{1}{2} \frac{\left(\sum_{i \in I_j} g_i \right)^2}{\sum_{i \in I_j} h_i + \lambda} + \alpha T \quad (14)$$

由此确定出第使木变函数最小的第 t 颗分类树的最优结构。

XGBoost 算法在选择最优分裂点时采用了随机子空间方法, 在节点的每一次分裂时, 对于不同的特征变量按比例随机选取特征值, 之后遍历随机选取的每一个特征值, 选择使增益函数最大的分裂点, 有效提高了模型的泛化能力, 避免了过拟合。在选择子树分裂点时, 定义增益函数:

$$Gain = \frac{1}{2} \left[\frac{\left(\sum_{i \in I_L} g_i \right)^2}{\sum_{i \in I_L} h_i + \lambda} + \frac{\left(\sum_{i \in I_R} g_i \right)^2}{\sum_{i \in I_R} h_i + \lambda} - \frac{\left(\sum_{i \in I_j} g_i \right)^2}{\sum_{i \in I_j} h_i + \lambda} \right] - \alpha \quad (15)$$

式中: $\sum_{i \in I_L} g_i, \sum_{i \in I_L} h_i$ 为分裂点左侧子树的梯度值; I_L 为左侧子树分裂点总集合; $\sum_{i \in I_R} g_i, \sum_{i \in I_R} h_i + \lambda$ 为分裂点右侧子树的梯度值; I_R 为右侧子树分裂点总集合。不断进行上述计算确定新树的最佳结构和最优分裂

节点, 通过集成新树提高模型预测精度。

3 CRITIC-XGB 岩爆预测模型的建立

将改进的 CRITIC 算法与 XGBoost 算法相结合并用于解决岩爆倾向的预测问题, 建立基于 CRITIC-XGB 算法的岩爆倾向等级预测模型。

3.1 岩爆等级判定指标的选取

岩爆是一种具有高度的复杂性和非线性的动力失稳现象, 其影响因素众多, 目前对岩爆发生的具体机制并未明确, 尚未形成统一理论标准, 但是, 在国内外众多专家学者研究了大量岩爆实例特征的基础上, 提出了岩爆发生的必要条件: 一是岩体处于高应力状态, 其主应力大小接近或者超过岩体本身强度; 二是岩石具有较大的弹性和较高的脆性, 即岩体在受力破坏过程中, 岩石破裂和变形消耗的能量相对于储存的能量较少, 剩余的势能转化为岩石的动能, 以岩体弹射、飞崩并产生强烈冲击波的形式瞬间释放, 形成岩爆^[15], 概括起来, 岩爆的发生与岩石应力状态、岩性、储存能量多少密切相关。

根据岩爆发生的上述必要条件和特征, 并结合对大量的岩爆实例数据和陈海军等^[8-11]的综合分析, 将岩爆等级分为 4 个等级: 无岩爆(或者无明显岩爆)、轻微岩爆、中等岩爆、强烈岩爆; 并选取 4 个物理量作为岩爆等级的判别指标, 即围岩切向应力 σ_θ , 围岩切向应力和单轴抗压强度的比值 σ_θ / σ_c , 岩石脆性指数 σ_c / σ_t , 岩石的弹性变形能量指数 W_{et} , 其中 W_{et} 为岩石受压变形过程中达到强度极限前积累的弹性应变能与塑性变形耗散的能量之比, 反映了岩石储存弹性变形能的能力强弱, 其值越大, 发生岩爆的概率就越大, 其计算模型为

$$W_{et} = \frac{E_e}{E_p} = \frac{\int_{\varepsilon_p}^{\varepsilon_t} f_1(\varepsilon) d\varepsilon}{\int_0^{\varepsilon_t} f(\varepsilon) d\varepsilon - \int_{\varepsilon_p}^{\varepsilon_t} f_1(\varepsilon) d\varepsilon} \quad (16)$$

式中: E_e 为岩石试件峰值载荷前的弹性变形储能; E_p 为岩石试件由于产生塑性变形和内部微破裂而消耗的能量; $f(\varepsilon)$, $f_1(\varepsilon)$ 分别为加卸载曲线; ε_t , ε_e , ε_p 分别为总应变、弹性应变和塑性应变。弹性变形能指数 W_{et} 计算模型示意图如图 1 所示。

3.2 CRITIC-XGB 岩爆预测模型的建立

3.2.1 基于改进的 CRITIC 算法的数据预处理

原始数据由于量纲的不同, 数据在数值大小上差别悬殊, 指标数据无法反映出其指标的重要程度,




图 1 弹性变形能指数 W_{et} 计算模型示意图

Fig.1 Schematic diagram of elastic deformation energy index W_{et} calculation model

在一定程度上会影响模型的精确性和收敛性能, 为了提高模型的收敛性能和预测效果, 必须对原始样本数据进行预处理。岩爆预测指标数值都是客观测定的, 不同的指标对于结果判定的贡献大小不同, 为了确定其指标的贡献度, 须对指标进行赋权。主观赋权法受人为影响太大, 不容易客观地反映其指标对于结果的贡献度, 所以本文采用客观赋权法对样本数据进行处理。考虑到岩爆预测指标之间相互具有一定的相关性, 本文选取改进的 CRITIC 法。

岩爆数据预处理步骤如下:

- (1) m 个岩爆样本的 4 个预测指标构成初始指标数据矩阵 $X = (x_{ij})_{m \times 4}$;
 - (2) 根据式(1)将各指标进行归一化, 消除指标间数据的差值过大问题;
 - (3) 再通过式(2)~(5)计算出 σ_θ , σ_θ / σ_c , σ_c / σ_t 和 W_{et} 四个指标所含的综合信息量;
 - (4) 根据综合信息量通过式(6)计算出各指标的综合权重;
 - (5) 根据式(7)得到最终的指标数据 $X^f = (x_{ij}^f)_{m \times 4}$ 。
- 运用改进的 CRITIC 法对样本数据进行预处理的流程如图 2 所示。

为了适应算法, 将岩爆等级转换成数字编码, 即无岩爆(或者无明显岩爆)、轻微岩爆、中等岩爆、强烈岩爆分别对应数字 1, 2, 3, 4。岩爆等级与处理后的指标组成最终数据矩阵 $X = (x_{ij})_{m \times 5}$ 。

3.2.2 基于 XGboost 算法的模型训练

预处理之后的样本数据矩阵用 XGBoost 算法进行模型训练, 其计算步骤如下:

- (1) 按一定比例从预处理后的样本里随机选取训练集;




图 2 基于 CRITIC 法的岩爆数据处理流程图
Fig.2 Flow chart of rockburst data processing based on CRITIC method

- (2) 根据式(8)构建 CART 树模型;
- (3) 根据式(9)获取模型的目标函数;
- (4) 根据式(10)~(14)计算目标函数最小值, 确定新树的最佳结构;
- (5) 根据式(15)增益函数计算最佳叶子节点, 构建出精度更高的新树;
- (6) 集成所有树模型, 构造出 XGBoost 岩爆倾向等级预测模型。

基于 XGBoost 算法的模型训练流程示意图如图 3 所示。




图 3 XGBoost 模型训练流程图
Fig.3 XGBoost model training flowchart

3.2.3 建立 CRITIC-XGB 岩爆倾向等级模型

将改进的 CRITIC 法预处理之后的岩爆数据样本运用 XGBoost 法进行训练, 并对模型进行参数调优, 从而建立起岩爆倾向等级的 CRITIC-XGB 预测模型。在进行岩爆倾向等级预测时, 预测指标作为

模型的输入特征向量, 岩爆预测等级作为模型的输出向量。

岩爆倾向等级预测的 CRITIC-XGB 模型建立流程如图 4 所示。




图 4 CRITIC-XGB 模型流程图
Fig.4 CRITIC-XGB model flow chart

4 实例分析

4.1 数据处理与模型建立

为了验证本文模型的有效性和可行性, 本文搜集了 50 组国内外岩爆实例数据^[8-10, 16], 依据节 3 的分析, 将数据进行整理, 其中 35 组数据用于模型的建立, 15 数据用于模型预测效果的测试。原始样本数据见表 1(表中, MR 为实际岩爆等级)。

使用改进的 CRITIC 法对原始样本数据进行处理, 其处理之后的数据如表 2 所示。

将预处理后的样本数据运用 XGBoost 算法进行迭代计算, 在经过若干次迭代, 分类器的误差趋于稳定后, 再进行算法的参数优化, 保存得到最优的 CRITIC-XGB 岩爆倾向等级预测模型。

4.2 岩爆等级预测结果及分析

将另外未参与模型建立的 15 组国内外岩爆实例的指标数据导入所建立的最优模型进行预测, 得到了岩爆的预测等级, 并将其与 XGBoost、RF、和 SVM 的预测结果作对比, 各方法预测结果如表 3 所示。

表 1 国内外岩爆实例数据
Table 1 Domestic and foreign rock burst example data

序号	σ_{θ} /MPa	σ_{θ}/σ_c	σ_c/σ_t	W_{et}	MR	序号	σ_{θ} /MPa	σ_{θ}/σ_c	σ_c/σ_t	W_{et}	MR
1	89.56	0.47	11.11	3.97	3	26	34.15	0.63	4.48	3.17	2
2	89.56	0.53	14.11	5.76	3	27	108.40	0.78	17.97	1.90	4
3	89.56	0.48	9.76	7.27	3	28	69.80	0.35	8.84	4.68	2
4	56.10	0.43	13.98	7.44	3	29	105.00	0.61	7.58	7.27	4
5	54.20	0.40	14.74	7.08	3	30	105.00	0.44	13.43	6.38	4
6	70.30	0.55	14.72	6.43	3	31	105.00	0.35	14.56	10.57	4
7	48.75	0.27	21.69	5.00	3	32	25.49	0.47	21.77	3.17	2
8	62.50	0.36	24.14	5.00	3	33	72.07	0.49	13.40	6.53	3
9	75.00	0.42	21.69	5.00	3	34	21.80	0.14	30.77	2.22	1
10	57.00	0.32	21.69	5.00	3	35	20.90	0.13	30.77	2.22	1
11	89.00	0.38	28.43	5.00	3	36*	12.10	0.08	30.77	2.22	1
12	50.00	0.38	21.67	5.00	3	37*	75.00	0.44	15.04	9.00	3
13	108.00	0.77	17.5	5.50	4	38*	43.40	0.35	20.50	5.00	3
14	18.80	0.11	31.23	7.40	1	39*	62.60	0.38	17.55	9.00	3
15	11.00	0.10	23.00	5.70	1	40*	30.00	0.34	23.97	6.60	3
16	55.40	0.31	24.11	9.30	3	41*	105.00	0.82	9.89	5.76	4
17	48.00	0.40	80.00	5.80	3	42*	105.00	0.35	33.33	5.76	3
18	63.00	0.55	76.67	5.70	3	43*	105.00	0.34	22.06	6.38	4
19	49.50	0.45	73.33	5.70	3	44*	7.50	0.14	14.05	1.30	1
20	30.90	0.37	12.70	3.20	2	45*	24.93	0.25	20.77	3.80	1
21	89.00	0.69	9.74	4.90	4	46*	14.96	0.15	20.77	3.80	1
22	12.30	0.05	13.43	6.90	1	47*	157.60	0.58	13.20	6.30	4
23	55.60	0.22	13.57	9.10	3	48*	148.40	0.45	17.50	5.10	3
24	91.30	0.40	13.12	7.30	4	49*	132.10	0.39	20.90	4.60	3
25	61.00	0.36	7.59	7.50	2	50*	167.20	0.66	13.20	6.80	4

注：带“*”的数据为测试组，下同。

表 2 处理后的岩爆样本数据
Table 2 Standardized rockburst sample data

序号	σ_{θ} /MPa	σ_{θ}/σ_c	σ_c/σ_t	W_{et}	MR
1	0.22	0.11	-0.10	-0.14	3
2	0.22	0.21	-0.07	0.01	3
3	0.22	0.13	-0.11	0.14	3
4	-0.42	0.11	0.00	-0.21	2
⋮	⋮	⋮	⋮	⋮	⋮
47*	0.04	0.14	-0.08	0.08	3
48*	0.80	0.08	-0.04	-0.05	3
49*	0.64	-0.01	-0.01	-0.09	3
50*	0.99	0.41	-0.08	0.10	4

表 3 各模型的岩爆等级预测结果
Table 3 Rockburst grade prediction results of each model

序号	MR	CRITIC-XGB 模型	XGBoost 模型	RF 模型	SVM 模型
36*	1	1	1	1	1
37*	3	3	3	3	3
38*	3	3	3	3	3
39*	3	3	3	3	3
40*	3	3	3	3	1
41*	4	4	4	4	4
42*	3	3	3	4	4
43*	4	4	3	4	4
44*	1	2	1	1	1
45*	1	1	1	2	1
46*	1	1	1	1	1
47*	4	4	4	4	4
48*	3	3	3	4	4
49*	3	3	4	4	4
50*	4	4	4	4	4

根据以上预测结果, 计算出 CRITIC-XGB 模型预测准确性为 93.3%, XGBoost 预测准确性为 86.7%, 随机森林法预测准确率为 73.3%, 支持向量机法预测准确性为 80%, 结果表明: CRITIC-XGB 模型的精度高于单独的 XGBoost 模型精度, 而且远高于随机森林和支持向量机的模型精度, 在样本容量较小的情况下, CRITIC-XGB 模型在岩爆倾向等级预测的问题上有着更高的准确性和可靠性。

为了进一步比较 CRITIC-XGB 和 XGBoost 模型的训练精度和收敛性能, 计算了其每一步迭代的训练误差, 结果如图 5 所示。




图 5 模型训练误差图

Fig.5 Model training error image

可以看出, 在模型收敛稳定后, CRITIC-XGB 的收敛误差为 2.8%, XGBoost 的收敛误差为 8.6%。在模型参数同为最优的情况下, CRITIC-XGB 预测模型的计算收敛能力显著强于 XGBoost 模型。进一步表明了 CRITIC-XGB 模型在岩爆预测方面的优越性。

以上实例分析结果表明了 CRITIC-XGB 岩爆倾向等级预测模型具有较高的预测准确性和良好的收敛稳定性能, 在岩爆倾向等级的预测方面有着较广泛的应用前景。

5 结 论

本文将 XGBoost 算法与改进的 CRITIC 算法相结合, 建立了岩爆倾向等级预测的 CRITIC-XGB 模型。并使用实例数据对模型进行验证, 结果表明: 模型预测正确率高达 93.3%, 表明了本文所建立的 CRITIC-XGB 模型对于岩爆倾向性预测是可靠的。

CRITIC-XGB 模型相比于 XGBoost 模型, 具有

更高的收敛速度和更高的预测精度, 表明改进的 CRITIC 法对提高 XGBoost 算法的预测准确性和稳定性有较为明显的效果, 进一步体现了两种算法集成的优越性。

将 CRITIC-XGB 模型预测结果与 XGBoost、随机森林法, 支持向量机的预测结果进行比较分析, 发现 CRITIC-XGB 模型明显具有更高的预测准确性, 表明了本文所建立的模型在解决岩爆倾向等级预测的方面, 具有较高可靠性和可行性, 是岩爆倾向等级预测的一种新的有效模型。

参考文献(References):

- [1] 许迎年, 徐文胜, 王元汉, 等. 岩爆模拟试验及岩爆机制研究[J]. 岩石力学与工程学报, 2002, 21(10): 1 462 - 1 466.(XU Yingnian, XU Wensheng, WANG Yuanhan, et al. Simulation testing and mechanism studies on rockburst[J]. Chinese Journal of Rock Mechanics and Engineering, 2002, 21(10): 1 462 - 1 466.(in Chinese))
- [2] 蔡嗣经, 张禄华, 周文略. 深井硬岩矿山岩爆灾害预测研究[J]. 中国安全生产科学技术, 2005, 1(5): 17 - 20.(CAI Sijing, ZHANG Luhua, ZHOU Wenlue. Research on prediction of rock burst in deep hard-rock mines[J]. Journal of Safety Science and Technology, 2005, 1(5): 17 - 20.(in Chinese))
- [3] 王元汉, 李卧东, 李启光, 等. 岩爆预测的模糊数学综合评判方法[J]. 岩石力学与工程学报, 1998, 17(5): 493 - 501.(WANG Yuanhan, LI Wodong, LI Qiguang, et al. Method of fuzzy comprehensive evaluations for rockburst prediction[J]. Chinese Journal of Rock Mechanics and Engineering, 1998, 17(5): 493 - 501.(in Chinese))
- [4] PACK K H, LEE J G, ADISORN O. Seepage force in a drained circular tunnel: an analytical approach[J]. Canadian Geotechnical Journal, 2008, 45(3): 432 - 436.
- [5] 袁继来, 林建入, 柯曾勇. 岩爆可能性估计的贝叶斯网络方法[C]// Proceedings of 2010 the 3rd International Conference on Computational Intelligence and Industrial Application. Piscataway, NJ: Institute of Electrical and Electronics Engineers, inc, 2011: 4.(YUAN Jilai, LIN Jianru, KE Cengyong. Bayesian network method for rockburst probability estimation[C]// Proceedings of 2010 the 3rd International Conference on Computational Intelligence and Industrial Application. Piscataway, NJ: Institute of Electrical and Electronics Engineers, inc, 2011: 4. (in Chinese))
- [6] 李绍红, 王少阳, 朱建东, 等. 基于权重融合和云模型的岩爆倾向性预测研究[J]. 岩土工程学报, 2018, 40(6): 1 075 - 1 083.(LI Shaohong, WANG Shaoyang, ZHU Jiandong, et al. Study on rockburst tendency prediction based on weight fusion and cloud model[J].

- Chinese Journal of Geotechnical Engineering, 2018, 40(6): 1 075 - 1 083.(in Chinese))
- [7] 谢学斌, 潘长良. 岩爆灾害的灰类白化权函数聚类预测方法[J]. 湖南大学学报: 自然科学版, 2007, 34(8): 16 - 20.(XIE Xuebin, PAN Changliang. Rockburst prediction method based on grey whitenization weight function cluster theory[J]. Journal of Hunan University: Natural Science, 2007, 34(8): 16 - 20.(in Chinese))
- [8] 陈海军, 酃能惠, 聂德新, 等. 岩爆预测的人工神经网络模型[J]. 岩土工程学报, 2002, 24(2): 229 - 232.(CHEN Haijun, ZHEN Nenghui, NIE Dexin, et al. A model for prediction of rockburst by artificial neural network[J]. Chinese Journal of Geotechnical Engineering, 2002, 24(2): 229 - 232.(in Chinese))
- [9] 赵洪波. 岩爆分类的支持向量机方法[J]. 岩土力学, 2005, 26(4): 642 - 644.(ZHAO Hongbo. Classification of rockburst using support vector machine[J]. Rock and Soil Mechanics, 2005, 26(4): 642 - 644.(in Chinese))
- [10] DONG L J, LI X B, PENG K. Prediction of rockburst classification using random forest[J]. Transactions of Nonferrous Metals Society of China, 2013, 23(2): 472 - 477.
- [11] DIAKOULAKI D, MAVROTAS G, PAPAYANNAKIS L. Determining objective weights in multiple criteria problems: The CRITIC method[J]. Computers and Operations Research, 1995, 22(7): 763 - 770.
- [12] 王 瑛, 蒋晓东, 张 璐. 基于改进的 CRITIC 法和云模型的科技奖励评价研究[J]. 湖南大学学报: 自然科学版, 2014, 41(4): 118 - 124.(WANG Ying, JIANG Xiaodong, ZHANG Lu. Research on the evaluation of science and technological awards based on improved CRITIC method and cloud model[J]. Journal of Hunan University: Natural Science, 2014, 41(4): 118 - 124.(in Chinese))
- [13] CHEN T, GUESTRIN C. XGBoost: a scalable tree boosting system[C]// Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining. San Francisco, USA: [s. n.], 2016: 85 - 97.
- [14] 闫星宇, 顾汉明, 肖逸飞, 等. XGBoost 算法在致密砂岩气储层测井解释中的应用[J]. 石油地球物理勘探, 2019, 54(2): 447 - 455.(YAN Xingyu, GU Hanming, XIAO Yifei, et al. Application of XGBoost algorithm in logging interpretation of tight sandstone gas reservoirs[J]. Petroleum Geophysical Prospecting, 2019, 54(2): 447 - 455.(in Chinese))
- [15] 江飞飞, 周 辉, 刘 畅, 等. 地下金属矿山岩爆研究进展及预测与防治[J]. 岩石力学与工程学报, 2019, 38(5): 956 - 972.(JIANG Feifei, ZHOU Hui, LIU Chang, et al. Research progress, prediction and prevention of rock burst in underground metal mines[J]. Chinese Journal of Rock Mechanics and Engineering, 2019, 38(5): 956 - 972.(in Chinese))
- [16] 崔铁军, 李莎莎, 王来贵, 等. 不同采深煤(岩)体岩爆过程模拟分析[J]. 计算力学学报, 2017, 34(3): 336 - 343.(CUI Tiejun, LI Shasha, WANG Laigui, et al. Simulation analysis of rockburst process of coal(rock) body with different depths[J]. Chinese Journal of Computational Mechanics, 2017, 34(3): 336 - 343.(in Chinese))

本刊 2020 年第 3, 4, 5, 6, 7 期被 EI COMPENDEX 分别 收录 17, 18, 20, 18, 18 篇(100%收录)

据“EI 中国”公布的数据显示, 本刊 2020 年第 39 卷第 3, 4, 5, 6, 7 期分别发表论文 17, 18, 20, 18, 18 篇, 被 EI COMPENDEX 收录论文共 91 篇, 收录率为 100%。

(摘自“EI 中国”)

2020 年 9 月 8 日